



UNIVERZITET U SARAJEVU
ELEKTROTEHNIČKI FAKULTET
ODSJEK ZA TELEKOMUNIKACIJE

Epidemic Routing Protocol

Kvaliteta usluge u telekomunikacijskim mrežama

Praktični izvještaj

Studenti:

Ajla Omerović
Lamija Klisura
Almina Tutnić

Predmetni nastavnik:

Van. prof. dr Miralem Mehić,
dipl.ing.el.

Sarajevo, juni 2026.

Sadržaj

1	Uvod	1
2	Opis rješenja	2
2.1	Princip rada Epidemic Routing protokola	2
3	Referentna implementacija	3
4	Scenariji simulacije	4
4.1	Prvi scenarij - Uticaj veličine bafera (Queue Length) na vjerovatnoću isporuke i gubitak paketa	4
4.2	Drugi scenarij - Uticaj maksimalnog broja skokova (Hop Count) na vjerovatnoću isporuke i gubitak paketa	4
4.3	Treći scenarij - Uticaj broja čvorova na vjerovatnoću isporuke i gubitak paketa .	5
4.4	Četvrti scenarij - Kombinovani uticaj mrežnih parametara	5
4.4.1	Podscenarij 4.1 – Uticaj veličine bafera i maksimalnog broja skokova .	5
4.4.2	Podscenarij 4.2 – Uticaj broja čvorova i veličine bafera	5
4.4.3	Podscenarij 4.3 – Uticaj broja čvorova i maksimalnog broja skokova . .	6
5	Analiza simulacijskih rezultata	7
5.1	Scenarij 1 – Uticaj veličine bafera (Queue Length)	7
5.2	Scenarij 2 – Uticaj maksimalnog broja skokova (Hop Count)	8
5.3	Scenarij 3 – Uticaj broja čvorova	9
5.4	Scenarij 4 – Kombinovani uticaj mrežnih parametara	10
5.4.1	Podscenarij 4.1 – Uticaj veličine bafera i maksimalnog broja skokova .	10
5.4.2	Podscenarij 4.2 – Uticaj broja čvorova i veličine bafera	11
5.4.3	Podscenarij 4.3 – Uticaj broja čvorova i maksimalnog broja skokova . .	12
5.5	Uporedna analiza scenarija	12
5.5.1	Komunikacijska analiza korištenjem Wireshark alata	13
6	Poređenje sa teorijskim vrijednostima	15
6.1	SI model širenja poruka	15
6.2	Prednosti i ograničenja – teorija vs. simulacija	15
6.3	Poređenje sa rezultatima iz literature	16
6.4	Ograničenja simulacijskog modela	16
7	Zaključak	17

Poglavlje 1

Uvod

Mreže otporne na kašnjenje (*Delay-Tolerant Networks – DTN*) predstavljaju poseban tip komunikacijskih mreža namijenjenih radu u uslovima gdje ne postoji stalna povezanost između čvorova. Za razliku od tradicionalnih TCP/IP mreža, kod kojih se pretpostavlja postojanje kompletne putanje između izvora i odredišta, DTN mreže funkcionišu u okruženjima sa čestim prekidima veze, velikim kašnjenjima i ograničenim mrežnim resursima. Zbog toga se u DTN arhitekturi koristi *Store-Carry-Forward* princip, pri kojem čvorovi privremeno skladište poruke i prenose ih tek kada ostvare kontakt sa drugim čvorovima.

Jedan od najpoznatijih protokola razvijenih za ovakva okruženja jeste *Epidemic Routing* protokol. Osnovna ideja ovog protokola zasniva se na intenzivnoj replikaciji poruka između čvorova, pri čemu svaki susret čvorova predstavlja priliku za razmjenu poruka koje nedostaju drugom čvoru. Na taj način postiže se veoma visoka vjerovatnoća isporuke poruka čak i u mrežama sa izrazito nestabilnom povezanošću. Međutim, veliki broj replika dovodi do povećanog mrežnog overhead-a, većeg opterećenja bafera i povećane potrošnje mrežnih resursa [1].

Teorijski su pojašnjeni osnovni principi rada DTN mreža, Store-Carry-Forward model, kao i način rada Epidemic Routing protokola i njegov uticaj na performanse mreže. Posebna pažnja posvećena je značaju simulacija u NS-3 okruženju i mogućnosti analize različitih parametara.

U okviru praktičnog dijela rada planirana je implementacija i analiza Epidemic Routing protokola u mrežnom simulatoru NS-3 korištenjem postojeće referentne implementacije dostupne na GitHub repozitoriju [2]. Cilj praktičnog dijela jeste analiza ponašanja protokola u različitim DTN scenarijima kroz izmjenu simulacionih parametara kao što su broj čvorova, veličina bafera, maksimalan broj skokova i trajanje poruke. Posebna pažnja posvećena je analizi performansi sistema kroz metrike kao što su vjerovatnoća isporuke poruka, prosječno kašnjenje, mrežni overhead i gubitak poruka.

Kroz simulacije u NS-3 okruženju omogućena je praktična evaluacija kompromisa između visoke pouzdanosti isporuke i povećane potrošnje mrežnih resursa, što predstavlja jedan od ključnih izazova Epidemic Routing pristupa u DTN mrežama.

Poglavlje 2

Opis rješenja

2.1 Princip rada Epidemic Routing protokola

Kao rješenje problema komunikacije u DTN mrežama koristi se *Epidemic Routing* protokol zasnovan na *Store-Carry-Forward* principu. Za razliku od tradicionalnih rutin protokola koji zahtijevaju postojanje kompletne putanje između izvora i odredišta, Epidemic Routing omogućava prenos podataka i u uslovima čestih prekida veze i nepouzdanosti između čvorova.

Osnovna ideja protokola zasniva se na intenzivnoj replikaciji poruka između čvorova. Svaki čvor u mreži posjeduje lokalni bafer u kojem skladišti poruke koje je generisao ili primio od drugih čvorova. Kada dva čvora dođu u međusobni komunikacijski domet, dolazi do razmjene informacija o sadržaju njihovih bafera putem *Summary Vector* mehanizma. Nakon poređenja sadržaja bafera, čvorovi međusobno razmjenjuju samo one poruke koje nedostaju drugom čvoru.

Na ovaj način poruke se postepeno šire kroz mrežu velikim brojem replika, čime se povećava vjerovatnoća da će poruka uspješno stići do odredišta čak i u mrežama sa izrazito nestabilnom povezanošću. Zbog svoje jednostavnosti i robusnosti, Epidemic Routing predstavlja jedan od osnovnih referentnih protokola za DTN mreže.

Međutim, intenzivna replikacija poruka uzrokuje i određene nedostatke. Veliki broj kopija poruka dovodi do povećanog mrežnog overhead-a, većeg opterećenja komunikacijskog kanala i popunjavanja bafera čvorova, što može rezultirati odbacivanjem poruka i degradacijom performansi sistema. Upravo zbog toga analiza kompromisa između visoke vjerovatnoće isporuke i potrošnje mrežnih resursa predstavlja jedan od ključnih aspekata istraživanja ovog protokola.

U okviru praktičnog dijela rada koristiće se postojeća implementacija Epidemic Routing protokola za NS-3 simulator dostupna na GitHub repozitoriju [2]. Implementacija omogućava simulaciju DTN mreža sa mobilnim čvorovima, definisanje parametara mreže i analizu performansi protokola kroz različite scenarije simulacije.

Planirano je ispitivanje uticaja različitih mrežnih parametara, kao što su broj čvorova, veličina bafera, maksimalan broj skokova i mrežni overhead, na performanse sistema. Dobijeni rezultati biće analizirani korištenjem metrika kao što su vjerovatnoća isporuke poruka, prosječno kašnjenje i gubitak poruka.

Poglavlje 3

Referentna implementacija

U okviru praktičnog dijela rada koristi se postojeća implementacija Epidemic Routing protokola za NS-3 simulator. Implementacija predstavlja benchmark alat namijenjen analizi performansi Epidemic Routing protokola u DTN mrežama.

Referentna simulacija modelira DTN mrežu sa 50 mobilnih čvorova raspoređenih u prostoru dimenzija $1500 \text{ m} \times 300 \text{ m}$. U okviru simulacije, 45 čvorova generiše poruke veličine 1 KB prema ostalim čvorovima u mreži, pri čemu ukupan broj generisanih poruka iznosi 1980. Mobilnost čvorova realizovana je korištenjem *Random Waypoint* modela kretanja, dok se komunikacija između čvorova ostvaruje kada se nalaze unutar definisanog komunikacijskog dometa.

Implementacija omogućava podešavanje velikog broja simulacionih parametara, među kojima su:

- broj čvorova u mreži,
- brzina kretanja čvorova,
- veličina paketa,
- komunikacijski domet,
- maksimalan broj skokova (*hop count*),
- veličina bafera (*queue length*),
- vrijeme trajanja poruke (*queue entry expire time*),
- interval beacon poruka.

Poseban značaj implementacije ogleda se u mogućnosti izvođenja različitih benchmark scenarija za analizu performansi protokola. U okviru repozitorija implementirani su:

- *Queue Length Benchmark* – analiza uticaja veličine bafera na performanse sistema,
- *Hop Count Benchmark* – analiza odnosa između maksimalnog broja skokova i gubitka poruka.

Rezultati simulacija mogu se prikazivati korištenjem Gnuplot alata, čime je omogućena grafička analiza performansi protokola kroz različite mrežne scenarije. Implementacija podržava pokretanje simulacija korištenjem Docker okruženja, što pojednostavljuje instalaciju i konfiguraciju potrebnih alata za izvođenje simulacija.

U okviru praktičnog dijela rada planirana je replikacija postojećih benchmark scenarija, kao i analiza uticaja različitih mrežnih parametara na performanse Epidemic Routing protokola u DTN mrežama.

Poglavlje 4

Scenariji simulacije

U okviru praktičnog dijela rada planirano je izvođenje nekoliko simulacionih scenarija s ciljem analize performansi Epidemic Routing protokola u različitim DTN uslovima rada. Posebna pažnja je posvećena ispitivanju uticaja ključnih mrežnih parametara na ponašanje sistema i efikasnost razmjene poruka između čvorova.

4.1 Prvi scenarij - Uticaj veličine bafera (Queue Length) na vjerovatnoću isporuke i gubitak paketa

U prvom scenariju analiziran je uticaj veličine bafera čvorova na performanse Epidemic Routing protokola. Parametar *queueLength* mijenjan je u opsegu od 0 do 2000, dok su ostali parametri simulacije konstantni. Kao metrike performansi posmatrani su vjerovatnoća isporuke poruka (*delivery ratio*) i gubitak paketa (*packet loss*). Cilj ovog scenarija je ispitati kako kapacitet bafera utiče na mogućnost skladištenja i prosljeđivanja poruka u DTN mreži. Za svaku vrijednost parametra *queueLength* izvršena je zasebna simulacija rada mreže. Kao osnovne metrike performansi posmatrani su vjerovatnoća isporuke poruka (*Delivery Ratio*) i gubitak paketa (*Packet Loss*).

Dobijeni rezultati omogućavaju analizu uticaja raspoloživog baferskog prostora na efikasnost Epidemic Routing protokola, pri čemu će detaljna interpretacija rezultata biti prikazana u narednom poglavlju.

4.2 Drugi scenarij - Uticaj maksimalnog broja skokova (Hop Count) na vjerovatnoću isporuke i gubitak paketa

U drugom scenariju analiziran je uticaj maksimalnog dozvoljenog broja skokova (*hop count*) na performanse Epidemic Routing protokola. Parametar *hopCount* mijenjan je u opsegu od 1 do 50, dok su ostali parametri simulacije zadržani nepromijenjeni. Cilj ovog scenarija je ispitati kako broj dozvoljenih skokova utiče na širenje poruka kroz DTN mrežu. Za svaku vrijednost parametra *hopCount* izvršena je zasebna simulacija rada mreže. Kao metrike performansi posmatrani su vjerovatnoća isporuke poruka (*Delivery Ratio*), gubitak paketa (*Packet Loss*) i mrežni overhead (*Overhead Ratio*).

Promjenom maksimalnog broja dozvoljenih skokova moguće je analizirati način na koji ograničenja u propagaciji poruka utiču na efikasnost Epidemic Routing protokola. Dobijeni

rezultati omogućavaju procjenu uticaja ovog parametra na uspješnost isporuke poruka i iskorištenost mrežnih resursa, dok će detaljna analiza rezultata biti prikazana u narednom poglavlju.

4.3 Treći scenarij - Uticaj broja čvorova na vjerovatnoću isporuke i gubitak paketa

U trećem scenariju analiziran je uticaj broja čvorova u mreži na performanse Epidemic Routing protokola. Parametar $nWifis$, koji predstavlja broj čvorova u mreži, mijenjan je u opsegu od 5 do 100, dok su ostali parametri simulacije zadržani nepromijenjeni. Cilj ovog scenarija je ispitati kako promjena gustine mreže utiče na proces razmjene i distribucije poruka u DTN okruženju. Za svaku vrijednost parametra $nWifis$ izvršena je zasebna simulacija rada mreže. Kao osnovne metrike performansi posmatrani su vjerovatnoća isporuke poruka (*Delivery Ratio*) i gubitak paketa (*Packet Loss*).

Promjenom broja čvorova moguće je ispitati uticaj gustine mreže na širenje i razmjenu poruka, kao i na performanse Epidemic Routing protokola. Dobijeni rezultati omogućavaju procjenu uticaja ovog parametra na uspješnost prenosa poruka kroz DTN mrežu, dok će detaljna analiza rezultata biti prikazana u narednom poglavlju.

4.4 Četvrti scenarij - Kombinovani uticaj mrežnih parametara

U cilju detaljnije analize performansi Epidemic Routing protokola izvedena su tri kombinovana podscenarija. Za razliku od prethodnih scenarija, gdje je mijenjan samo jedan parametar, u ovom slučaju istovremeno se mijenjaju dva parametra, dok treći ostaje konstantan. Na taj način moguće je analizirati međusobni uticaj različitih mrežnih parametara na performanse sistema.

4.4.1 Podscenarij 4.1 – Uticaj veličine bafera i maksimalnog broja skokova

U prvom podscenariju istovremeno se mijenjaju parametri *queueLength* i *hopCount*, dok broj čvorova ostaje konstantan ($nWifis = 50$). Cilj je analizirati zajednički uticaj kapaciteta bafera i maksimalnog broja dozvoljenih skokova na vjerovatnoću isporuke poruka i gubitak paketa. Vrijednosti parametra *queueLength* mijenjane su u širokom opsegu, dok su istovremeno mijenjane i vrijednosti parametra *hopCount*. Na taj način formiran je skup različitih konfiguracija koje omogućavaju analizu međusobnog djelovanja ova dva parametra tokom procesa širenja poruka kroz DTN mrežu. Za svaku kombinaciju parametara izvršena je zasebna simulacija rada mreže. Kao osnovne metrike performansi posmatrani su vjerovatnoća isporuke poruka (*Delivery Ratio*) i gubitak paketa (*Packet Loss*).

Dobijeni rezultati omogućavaju procjenu uticaja kapaciteta bafera i maksimalnog broja dozvoljenih skokova na efikasnost Epidemic Routing protokola. Detaljna analiza i poređenje ostvarenih rezultata prikazani su u narednom poglavlju.

4.4.2 Podscenarij 4.2 – Uticaj broja čvorova i veličine bafera

U drugom podscenariju mijenjaju se parametri $nWifis$ i *queueLength*, dok je maksimalni broj skokova konstantan ($hopCount = 50$). Cilj je analizirati kako istovremene promjene gustine

mreže i kapaciteta bafera utiču na efikasnost Epidemic Routing protokola. Vrijednosti parametra *nWifs*, koji predstavlja broj čvorova u mreži, mijenjane su zajedno sa vrijednostima parametra *queueLength*. Na taj način formiran je skup različitih simulacionih konfiguracija koje omogućavaju analizu međusobnog djelovanja gustine mreže i raspoloživog baferskog prostora. Za svaku kombinaciju parametara izvršena je zasebna simulacija rada mreže. Kao osnovne metrike performansi posmatrani su vjerovatnoća isporuke poruka (*Delivery Ratio*) i gubitak paketa (*Packet Loss*).

Dobijeni rezultati omogućavaju procjenu uticaja broja čvorova i veličine bafera na efikasnost prenosa poruka kroz DTN mrežu. Detaljna analiza ostvarenih rezultata i poređenje različitih konfiguracija prikazani su u narednom poglavlju.

4.4.3 Podscenarij 4.3 – Uticaj broja čvorova i maksimalnog broja skokova

U trećem podscenariju mijenjaju se parametri *nWifs* i *hopCount*, dok veličina bafera ostaje konstantna (*queueLength* = 1000). Na ovaj način ispituje se međusobni uticaj gustine mreže i broja dozvoljenih skokova na uspješnost prenosa poruka kroz DTN mrežu. Vrijednosti parametra *nWifs*, koji predstavlja broj čvorova u mreži, mijenjane su zajedno sa vrijednostima parametra *hopCount*. Na taj način formiran je skup različitih simulacionih konfiguracija koje omogućavaju analizu međusobnog djelovanja gustine mreže i ograničenja propagacije poruka kroz DTN mrežu.


Kao i u prethodna dva podscenarija i ovdje su kao osnovne metrike performansi posmatrani vjerovatnoća isporuke poruka (*Delivery Ratio*) i gubitak paketa (*Packet Loss*). Također, detaljna analiza ostvarenih rezultata prikazana je u narednom poglavlju.

Poglavlje 5

Analiza simulacijskih rezultata

U ovom poglavlju prikazani su rezultati simulacije Epidemic Routing protokola kroz četiri scenarija. Za svaki scenarij analizirani su uticaji ključnih mrežnih parametara na vjerovatnoću isporuke poruka (*delivery ratio*), gubitak paketa (*packet loss*) i mrežni overhead (*Overhead Ratio*).

5.1 Scenarij 1 – Uticaj veličine bafera (Queue Length)



Slika 5.1: Uticaj veličine bafera (Queue Length) na vjerovatnoću isporuke i gubitak paketa


Na Slici 5.1 prikazan je uticaj veličine bafera (*Queue Length*) na vjerovatnoću isporuke poruka (*Delivery Ratio*) i gubitak paketa (*Packet Loss*) u Epidemic Routing protokolu. Parametar *queueLength* mijenjan je u opsegu od 0 do 2000 paketa, dok su ostali parametri simulacije ostali nepromijenjeni ($nWifs = 50$, $maxHopCount = 50$).

Rezultati pokazuju da pri veličini bafera od 0 paketa nijedna poruka nije uspješno isporučena, te je zabilježen gubitak paketa od 100%. Povećanjem kapaciteta bafera dolazi do postepenog rasta vjerovatnoće isporuke i smanjenja gubitka paketa. Najveća vrijednost vjerovatnoće isporuke ostvarena je pri veličini bafera od 1200 paketa, gdje *Delivery Ratio* dostiže približno 32.4%, dok se *Packet Loss* smanjuje na oko 67.6%.

Nakon dostizanja maksimalne vrijednosti vjerovatnoće isporuke, daljnje povećanje kapaciteta bafera ne dovodi do značajnog poboljšanja performansi. Iako se uočavaju manje oscilacije vrijednosti *Delivery Ratio* i *Packet Loss*, ukupni rezultati ukazuju na postojanje optimalne vrijednosti parametra *queueLength* za posmatrani scenarij. Dobijeni rezultati potvrđuju da povećanje kapaciteta bafera omogućava čvorovima skladištenje većeg broja replika poruka, čime se povećava vjerovatnoća njihove uspješne isporuke kroz DTN mrežu. Međutim, nakon određene granice dodatno povećanje veličine bafera ne donosi poboljšanje performansi, što ukazuje na postojanje zasićenja sistema i ograničene iskorištenosti dodatnih mrežnih resursa.

5.2 Scenarij 2 – Uticaj maksimalnog broja skokova (Hop Count)

Pored vjerovatnoće isporuke poruka i gubitka paketa, u ovom scenariju analiziran je i mrežni overhead (*Overhead Ratio*), s obzirom na to da parametar *hopCount* direktno utiče na broj proslijeđivanja i replika poruka u mreži. Na taj način moguće je procijeniti odnos između uspješnosti isporuke poruka i dodatnog opterećenja koje nastaje usljed povećanja broja dozvoljenih skokova.



Slika 5.2: Uticaj maksimalnog broja skokova (Hop Count) na vjerovatnoću isporuke, gubitak paketa i mrežni overhead


Na Slici 5.2 prikazan je uticaj maksimalnog broja dozvoljenih skokova (*Hop Count*) na vjerovatnoću isporuke poruka (*Delivery Ratio*), gubitak paketa (*Packet Loss*) i mrežni overhead Epidemic Routing protokola. Parametar *hopCount* mijenjan je u opsegu od 1 do 50, dok su ostali parametri simulacije ostali nepromijenjeni ($nWifis = 50$, $queueLength = 2000$).

Rezultati pokazuju da male vrijednosti parametra *hopCount* značajno ograničavaju mogućnost širenja poruka kroz mrežu. Pri $hopCount = 1$ zabilježena je najniža vrijednost vjerovatnoće isporuke od 12.32%, dok se povećanjem broja dozvoljenih skokova *delivery ratio* postepeno povećava. Najveća vrijednost vjerovatnoće isporuke ostvarena je pri $hopCount = 29$, gdje *delivery ratio* dostiže približno 30%, dok se gubitak paketa smanjuje na oko 70%.

Nakon ove vrijednosti primjećuju se oscilacije rezultata bez značajnijeg poboljšanja performansi, što ukazuje da poruke već uspješno prolaze kroz mrežu te dodatni dozvoljeni skokovi uglavnom povećavaju broj replika bez značajnog doprinosa uspješnosti isporuke. Mrežni over-

head (zeleni linija) ostaje relativno nizak i stabilan tokom cijelog posmatranog raspona vrijednosti parametra *hopCount*. To ukazuje da povećanje maksimalnog broja dozvoljenih skokova doprinosi efikasnijem širenju poruka i povećanju vjerovatnoće njihove uspješne isporuke, bez značajnog dodatnog opterećenja mrežnih resursa. Dobijeni rezultati potvrđuju da se u analiziranom scenariju može postići bolji kvalitet prenosa uz očuvanje zadovoljavajućeg nivoa mrežne efikasnosti.

5.3 Scenarij 3 – Uticaj broja čvorova



Slika 5.3: Uticaj broja čvorova (*nWifis*) na vjerovatnoću isporuke i gubitak paketa


Na Slici 5.3 prikazan je uticaj broja čvorova (*nWifis*) na vjerovatnoću isporuke poruka (*Delivery Ratio*) i gubitak paketa (*Packet Loss*) u Epidemic Routing protokolu. Parametar *nWifis* mijenjan je u opsegu od 5 do 100 čvorova, dok su ostali parametri simulacije ostali nepromijenjeni (*queueLength* = 2000, *hopCount* = 50).

Rezultati pokazuju da pri minimalnom broju čvorova (*nWifis* = 5) nijedna poruka nije uspješno isporučena, što je posljedica nedovoljnog broja susreta između čvorova za efikasno širenje poruka kroz mrežu. Povećanjem broja čvorova dolazi do rasta vjerovatnoće isporuke jer se povećava broj mogućih susreta i prilika za razmjenu poruka. Najveća vrijednost vjerovatnoće isporuke ostvarena je pri 45 čvorova, gdje *Delivery Ratio* dostiže približno 27.8%, dok se *Packet Loss* smanjuje na oko 72.2%.

Nakon ove optimalne vrijednosti primjećuje se postepeno opadanje vjerovatnoće isporuke i rast gubitka paketa. Razlog ovakvog ponašanja leži u prirodi Epidemic Routing protokola, gdje veći broj čvorova uzrokuje intenzivniju replikaciju poruka i brže popunjavanje bafera. Ovo rezultira odbacivanjem poruka i degradacijom performansi sistema. Dobijeni rezultati potvrđuju da za posmatrani scenarij postoji optimalan broj čvorova pri kojem se ostvaruje najbolji odnos između dostupnosti poruka i iskorištenosti mrežnih resursa.

5.4 Scenarij 4 – Kombinovani uticaj mrežnih parametara

5.4.1 Podscenarij 4.1 – Uticaj veličine bafera i maksimalnog broja skokova




Slika 5.4: Kombinovani uticaj veličine bafera i maksimalnog broja skokova na vjerovatnoću isporuke i gubitak paketa ($nWifs = 50$)

Na Slici 5.4 prikazan je column chart za podscenarij 4.1, u kojem se istovremeno mijenjaju veličina bafera (queueLength) i maksimalni broj dozvoljenih skokova (hopCount). Za svaku kombinaciju parametara prikazane su vrijednosti Delivery Ratio i Packet Loss, što omogućava direktno poređenje uspješnosti prenosa poruka i gubitka paketa. Može se primijetiti da povećanje vrijednosti queueLength i hopCount u početnom dijelu simulacije dovodi do postepenog povećanja Delivery Ratio sa približno 6% na više od 26%, dok se Packet Loss istovremeno smanjuje sa preko 94% na približno 73%. Najbolji rezultat ostvaren je za kombinaciju $queueLength = 1000$ i $hopCount = 200$, gdje Delivery Ratio dostiže približno 26.6%, dok Packet Loss pada na oko 73.4%.

Nakon dostizanja optimalne kombinacije parametara dolazi do zasićenja sistema. Daljnje povećavanje veličine bafera i broja dozvoljenih skokova ne donosi značajno poboljšanje performansi, pa se Delivery Ratio stabilizuje na vrijednostima oko 21–22%, dok Packet Loss ostaje približno konstantan na nivou od 78%. Ovakvo ponašanje ukazuje da povećavanje resursa mreže iznad određene granice ne rezultira proporcionalnim poboljšanjem uspješnosti isporuke poruka.

Dobijeni rezultati potvrđuju da postoji optimalan odnos između veličine bafera i maksimalnog broja skokova. Premale vrijednosti ovih parametara ograničavaju mogućnost širenja poruka kroz mrežu, dok prevelike vrijednosti dovode do povećanog opterećenja mreže bez značajnog povećanja vjerovatnoće uspješne isporuke.

5.4.2 Podscenarij 4.2 – Uticaj broja čvorova i veličine bafera



Slika 5.5: Kombinovani uticaj broja čvorova i veličine bafera na vjerovatnoću isporuke i gubitak paketa (*hopCount* = 50)


Na Slici 5.5 prikazan je column chart za podscenarij 4.2, u kojem se istovremeno mijenjaju broj čvorova u mreži (*nWifis*) i veličina bafera (*queueLength*), dok vrijednost parametra *hopCount* ostaje konstantna i iznosi 50. Za svaku kombinaciju parametara prikazane su vrijednosti Delivery Ratio i Packet Loss, čime je omogućena detaljna analiza njihovog zajedničkog uticaja na performanse Epidemic Routing protokola.

Rezultati pokazuju da povećanje broja čvorova i veličine bafera u početnom dijelu simulacije dovodi do postepenog poboljšanja uspješnosti isporuke poruka. Delivery Ratio raste sa približno 5.8% za kombinaciju *nWifis* = 50 i *queueLength* = 100 do maksimalne vrijednosti od približno 37.8%, ostvarene pri kombinaciji *nWifis* = 30 i *queueLength* = 3000. Istovremeno, Packet Loss opada sa preko 94% na približno 62%, što predstavlja najbolji rezultat posmatranog podscenarija.

Nakon dostizanja optimalne kombinacije parametara dolazi do pogoršanja performansi. Iako se veličina bafera dodatno povećava, Delivery Ratio se smanjuje, dok Packet Loss ponovo raste. Posebno se izdvaja kombinacija *nWifis* = 10 i *queueLength* = 5000, kod koje Delivery Ratio pada na približno 2.2%, dok Packet Loss dostiže gotovo 98%. Ovakav rezultat pokazuje da povećanje veličine bafera samo po sebi nije dovoljno za poboljšanje performansi ukoliko mreža ne sadrži dovoljan broj čvorova koji mogu međusobno komunicirati.

Dobijeni rezultati potvrđuju da postoji optimalan odnos između broja čvorova i veličine bafera. Premali broj čvorova ograničava mogućnost razmjene poruka u mreži, dok prevelike vrijednosti pojedinih parametara mogu dovesti do povećanog opterećenja i neefikasnog korištenja mrežnih resursa. Najbolje performanse ostvaruju se pri uravnoteženoj kombinaciji oba parametara, gdje je omogućena dovoljna frekvencija kontakata između čvorova uz adekvatan kapacitet za pohranu i prosljeđivanje poruka.

5.4.3 Podscenarij 4.3 – Uticaj broja čvorova i maksimalnog broja skokova



Slika 5.6: Kombinovani uticaj broja čvorova i maksimalnog broja skokova na vjerovatnoću isporuke i gubitak paketa (*queueLength* = 1000)

Na Slici 5.6 prikazan je column chart za Podscenarij 4.3, u kojem se istovremeno mijenjaju broj čvorova u mreži (*nWifis*) i maksimalni broj dozvoljenih skokova (*hopCount*), dok veličina bafera (*queueLength*) ostaje konstantna i iznosi 1000 paketa. Prikazane su vrijednosti Delivery Ratio i Packet Loss za svaku kombinaciju parametara, što omogućava analizu njihovog zajedničkog uticaja na performanse Epidemic Routing protokola.

Rezultati pokazuju da smanjenje broja čvorova uz istovremeno prilagođavanje vrijednosti parametra *hopCount* može dovesti do značajnog poboljšanja uspješnosti isporuke poruka. Delivery Ratio raste sa približno 26.6% za kombinaciju *nWifis* = 50 i *hopCount* = 50 do maksimalne vrijednosti od približno 39.0%, ostvarene pri kombinaciji *nWifis* = 30 i *hopCount* = 65. Istovremeno, Packet Loss opada sa približno 73% na oko 61%, što predstavlja najbolji rezultat posmatranog podscenarija.

Nakon dostizanja optimalne kombinacije parametara dolazi do postepenog pogoršanja performansi. Daljnje smanjenje broja čvorova i promjena vrijednosti parametra *hopCount* uzrokuju smanjenje Delivery Ratio i povećanje Packet Loss. Posebno se izdvaja kombinacija *nWifis* = 10 i *hopCount* = 40, kod koje Delivery Ratio pada na približno 2.2%, dok Packet Loss dostiže gotovo 98%. Ovakav rezultat pokazuje da mali broj čvorova značajno smanjuje mogućnost susreta između čvorova potrebnih za uspješnu razmjenu poruka, bez obzira na vrijednost parametra *hopCount*.

Može se zaključiti da broj čvorova i maksimalni broj dozvoljenih skokova predstavljaju međusobno povezane parametre koji značajno utiču na performanse DTN mreže. Veće vrijednosti parametra *hopCount* omogućavaju porukama da prolaze kroz veći broj posrednih čvorova prije odbacivanja, dok odgovarajući broj čvorova povećava vjerovatnoću susreta. Najbolje performanse ostvaruju se pri uravnoteženoj kombinaciji oba parametra, gdje je omogućena efikasna distribucija poruka kroz mrežu uz minimalan gubitak paketa.

5.5 Uporedna analiza scenarija

Na osnovu provedenih simulacija moguće je izvršiti uporednu analizu performansi Epidemic Routing protokola kroz sve posmatrane scenarije. Tabela 5.1 prikazuje sumarni pregled ključ-

nih rezultata, uključujući optimalne vrijednosti parametara pri kojima je ostvarena najveća vjerojatnoća isporuke poruka.

Tabela 5.1: Sumarni pregled rezultata simulacionih scenarija

Scenarij	Optimalni parametri	Max Delivery Ratio	Min Packet Loss
Scenarij 1 – Queue Length	<i>queueLength</i> = 1200	32.4%	67.6%
Scenarij 2 – Hop Count	<i>hopCount</i> = 29	30.0%	70.0%
Scenarij 3 – Broj čvorova	<i>nWifis</i> = 45	27.8%	72.2%
Podscenarij 4.1	<i>queueLength</i> = 1000, <i>hopCount</i> = 200	26.6%	73.4%
Podscenarij 4.2	<i>nWifis</i> = 30, <i>queueLength</i> = 3000	37.8%	62.2%
Podscenarij 4.3	<i>nWifis</i> = 30, <i>hopCount</i> = 65	39.0%	61.0%

Posmatrajući rezultate iz Tabele 5.1, mogu se uočiti nekoliko ključnih zaključaka:

- Među scenarijima sa jednim promjenjivim parametrom, **Scenarij 1** (veličina bafera) ostvaruje najbolje rezultate sa *delivery ratio* od 32.4%, što potvrđuje da kapacitet bafera ima najznačajniji individualni uticaj na performanse protokola.
- Kombinovani scenariji generalno ostvaruju bolje performanse u odnosu na scenarije sa jednim promjenjivim parametrom, što ukazuje na pozitivan efekat istovremene optimizacije više mrežnih parametara.
- **Podscenarij 4.3** (broj čvorova + hop count) ostvaruje najbolje ukupne rezultate sa *delivery ratio* od 39.0% i *packet loss* od 61.0%, što potvrđuje da je kombinacija gustine mreže i broja dozvoljenih skokova najuticajniji faktor u performansama Epidemic Routing protokola.
- Uprkos optimalnim podešavanjima parametara, *packet loss* u svim scenarijima ostaje visok (iznad 60%), što je karakteristično ponašanje Epidemic Routing protokola usljed intenzivne replikacije poruka i ograničenog kapaciteta bafera.

5.5.1 Komunikacijska analiza korištenjem Wireshark alata

U cilju provjere ispravnosti rada implementiranog Epidemic Routing protokola izvršena je komunikacijska analiza korištenjem alata Wireshark. Nakon pokretanja simulacije u NS-3 okruženju generisani su PCAP fajlovi koji sadrže mrežni saobraćaj svakog čvora u simulaciji. Svaki PCAP fajl predstavlja zapis svih paketa koje je određeni čvor poslao ili primio tokom izvršavanja simulacije. Video snimak kompletne realizacije simulacije i komunikacijske analize dostavljen je kao sastavni dio projekta.

Za analizu komunikacije odabran je jedan od generisanih PCAP fajlova i otvoren u Wireshark alatu. Pregledom sadržaja moguće je uočiti razmjenu paketa između različitih čvorova u mreži. Analiza prikazuje korištenje IEEE 802.11 bežičnog sloja, IPv4 mrežnog protokola i UDP transportnog protokola, što odgovara načinu komunikacije implementirane simulacije.

Detaljnim pregledom pojedinačnih paketa moguće je analizirati izvorišnu i odredišnu IP adresu, korištene portove, veličinu paketa, kao i ostale informacije sadržane u zaglavlju paketa. Na prikazanom primjeru evidentirana je UDP komunikacija između čvorova sa IP adresama 10.1.1.7 i 10.1.1.32, pri čemu je veličina analiziranog paketa iznosila 1104 bajta.

Pored pregleda pojedinačnih paketa, korištene su i statističke mogućnosti Wireshark alata. Opcija *Conversations* omogućava pregled svih komunikacionih tokova između čvorova u mreži, uključujući broj razmijenjenih paketa, količinu prenesenih podataka i trajanje komunikacije između pojedinih parova čvorova. Na taj način moguće je steći uvid u intenzitet razmjene poruka tokom rada Epidemic Routing protokola.

Dodatno je analizirana i opcija *Protocol Hierarchy*, koja prikazuje zastupljenost svih mrežnih protokola korištenih tokom simulacije. Dobijeni rezultati pokazuju da se komunikacija odvija preko IEEE 802.11 bežične mreže uz korištenje IPv4 i UDP protokola, čime je potvrđeno da je simulacija uspješno generisala očekivani mrežni saobraćaj. Wireshark prikazuje mrežne pakete koje je generisala simulacija, dok se prisustvo Epidemic Routing protokola potvrđuje načinom pokretanja simulacije, generisanim PCAP zapisima i karakterističnom razmjenom UDP paketa između velikog broja čvorova.

Poglavlje 6

Poređenje sa teorijskim vrijednostima

Teorijski dio rada definisao je očekivano ponašanje Epidemic Routing protokola kroz nekoliko ključnih modela i predviđanja. U ovom poglavlju vrši se poređenje tih teorijskih predviđanja sa rezultatima dobijenim kroz simulacije u NS-3 okruženju.

6.1 SI model širenja poruka

U teorijskom dijelu rada, širenje poruka u Epidemic Routing protokolu opisano je modifikovanim SI (Susceptible-Infected) modelom, definisanim diferencijalnom jednačinom:

$$\frac{dI(t)}{dt} = \beta I(t)[N - I(t)] \quad (6.1)$$

Ovaj model predviđa da širenje poruke prati *logističku krivu*, gdje je u početnoj fazi širenje gotovo eksponencijalno, a kako se broj podložnih čvorova $[N - I(t)]$ smanjuje, stopa rasta opada sve dok svi čvorovi ne posjeduju informaciju.

Rezultati iz Scenarija 3 (uticaj broja čvorova) potvrđuju ovo teorijsko predviđanje. Pri malom broju čvorova ($nWifs = 5$) zabilježen je *delivery ratio* od 0%, što odgovara početnoj fazi SI modela gdje je $I(t)$ minimalno. Povećanjem broja čvorova dolazi do ubrzanog rasta vjerovatnoće isporuke, što je konzistentno sa eksponencijalnom fazom logističke krive. Maksimum je dostignut pri 45 čvorova (27.8%), nakon čega dolazi do pada performansi usljed zagušenja bafera. Ovo je efekat koji SI model ne modelira direktno, ali koji je predviđen kao ograničenje u teorijskom dijelu rada.

6.2 Prednosti i ograničenja – teorija vs. simulacija

Teorijski dio rada identificirao je sljedeće ključne karakteristike Epidemic Routing protokola, koje su potvrđene kroz simulacije:

- **Visoka vjerovatnoća isporuke kroz replikaciju** – Teorija predviđa da protokol postiže teorijski najnižu granicu kašnjenja isporuke kroz replikaciju poruka. Simulacije su potvrdile ovu karakteristiku, gdje Epidemic routing dostiže visoke vrijednosti *delivery ratio* u poređenju sa scenarijima gdje su resursi ograničeni, posebno u Podscenariju 4.3 gdje je ostvareno 39.0%.
- **Flooding overhead** – Teorijski dio upozorava na "plavljenje" (*flooding overhead*) kao glavni nedostatak protokola. Simulacije su jasno potvrdile ovaj problem gdje *packet loss*

ostaje visok (iznad 60%) u svim scenarijima, što je direktna posljedica intenzivne replikacije i zagušenja bafera.

- **Uticaj kapaciteta bafera** – Teorija ističe ograničen kapacitet bafera kao kritičan resurs u DTN mrežama. Scenarij 1 je eksplicitno potvrdio ovu tvrdnju, gdje je pri *queueLength* = 0 zabilježen gubitak od 100% poruka, dok se povećanjem bafera *delivery ratio* poboljšava do optimalnih 32.4%.
- **Parametar hop count** – Teorijski dio opisuje *hop count* kao mehanizam djelomične kontrole nad resursima. Scenarij 2 je potvrdio da mali *hopCount* značajno ograničava širenje poruka (pri *hopCount* = 1, *delivery ratio* = 12.32%), dok veće vrijednosti omogućavaju bolje propagiranje kroz mrežu.

6.3 Poređenje sa rezultatima iz literature

Teorijski dio rada prikazuje rezultate iz literature [3] koji analiziraju performanse Epidemic protokola pri varijaciji veličine bafera u rasponu od 5 MB do 35 MB. Ti rezultati pokazuju da Epidemic protokol zadržava najveću vjerovatnoću isporuke u poređenju sa PROPHET, Spray and Wait i Binary Spray and Wait protokolima, uz napomenu da intenzivna replikacija dovodi do ekstremno visokih vrijednosti mrežnog overhead-a.

Simulacije iz ovog rada su konzistentne sa ovim zaključcima:

- Epidemic routing dostiže relativno visoke vrijednosti *delivery ratio* (do 39.0%) u odnosu na scenarije sa ograničenim resursima, što potvrđuje teorijsku prednost protokola u pogledu pouzdanosti isporuke.
- Visok *packet loss* (iznad 60% u svim scenarijima) potvrđuje teorijski identificiran problem prekomjernog overhead-a karakterističnog za Epidemic routing.
- Rezultati pokazuju da povećanje bafera i broja dozvoljenih skokova poboljšava performanse samo do određene granice, što je u skladu sa teorijskim predviđanjem o zasićenju sistema.

6.4 Ograničenja simulacijskog modela

Kao što je navedeno u teorijskom dijelu rada, NS-3 simulacija ima određena ograničenja u odnosu na idealne teorijske uslove. Modeli mobilnosti poput *Random Waypoint* ne odražavaju u potpunosti realne obrasce kretanja čvorova. Pored toga, simulacijski prostor dimenzija 1500 m × 300 m predstavlja usku traku koja ograničava broj mogućih susreta između čvorova, što objašnjava zašto su ostvarene vrijednosti *delivery ratio* niže od teorijski predviđenih vrijednosti za idealne DTN uslove.

Poglavlje 7

Zaključak

U okviru ovog rada izvršena je implementacija i analiza Epidemic Routing protokola u NS-3 simulacionom okruženju s ciljem ispitivanja uticaja različitih mrežnih parametara na performanse DTN mreže. Kroz provedene simulacije analiziran je uticaj veličine bafera, maksimalnog broja skokova i broja čvorova, kao i njihov zajednički uticaj u kombinovanim scenarijima. Kao osnovne metrike performansi posmatrani su vjerovatnoća isporuke poruka (Delivery Ratio), gubitak paketa (Packet Loss), prosječno kašnjenje i mrežni overhead.

Rezultati simulacija pokazali su da svaki od analiziranih parametara značajno utiče na ponašanje Epidemic Routing protokola. Povećanje veličine bafera omogućava skladištenje većeg broja poruka i povećava vjerovatnoću njihove isporuke, dok odgovarajuće povećanje maksimalnog broja skokova omogućava uspješnije širenje poruka kroz mrežu. Također, analiza broja čvorova pokazala je da postoji optimalna gustina mreže pri kojoj se ostvaruju najbolje performanse, dok prevelik ili premali broj čvorova dovodi do pogoršanja rezultata.

Najbolje ukupne rezultate ostvario je podscenarij 4.3, u kojem je za kombinaciju parametara $nWifis = 30$ i $hopCount = 65$ ostvarena najveća vjerovatnoća isporuke poruka od približno 39%, uz najmanji gubitak paketa od oko 61%. Dobijeni rezultati pokazuju da istovremena optimizacija više mrežnih parametara daje bolje performanse od njihove pojedinačne promjene.

Pored analize simulacionih rezultata, izvršena je i komunikacijska analiza korištenjem Wireshark alata, čime je potvrđena ispravnost generisanog mrežnog saobraćaja i razmjene UDP paketa između čvorova. Na osnovu generisanih PCAP zapisa analizirani su komunikacioni tokovi, korišteni mrežni protokoli i statistika razmjene paketa, što predstavlja dodatnu potvrdu ispravnosti implementirane simulacije.

Na osnovu svih provedenih analiza može se zaključiti da Epidemic Routing predstavlja jednostavan i pouzdan protokol za DTN mreže, posebno u uslovima čestih prekida veze i nepostojanja potpune komunikacijske putanje između čvorova. Međutim, intenzivna replikacija poruka uzrokuje povećano opterećenje mreže i značajan gubitak paketa, zbog čega je pravilno podešavanje mrežnih parametara od ključnog značaja za postizanje što boljeg kompromisa između pouzdanosti isporuke i efikasnog korištenja mrežnih resursa.

Literatura

- [1] Vahdat, A. and Becker, D. (2000). *Epidemic routing for partially connected ad hoc networks*. Technical Report CS-200006, Duke University.
- [2] Herbrant, “Epidemic Routing ns-3 Benchmark Implementation,” GitHub repository, [Online]. Available: <https://github.com/Herbrant/epidemic-ns3>.
- [3] Yulianti, D., Mandala, S., Nasien, D., Ngadi, A., and Coulibaly, Y. (2020). *Performance comparison of epidemic, prophet, spray and wait, binary spray and wait, and prophetv2*. Faculty of Computing, Universiti Teknologi Malaysia.